

AGENT FORGE AI HACKATHON SEOUL · 2026.08.22

# Does It Actually Run?

README대로 진짜 되는지, 격리 샌드박스에서 **실제로 돌려보고** 판정합니다.

We don't ask a model whether it works. We run it, and read the exit code.

Bright Data

Qwen Cloud

Daytona

Nosana

# README대로 하면, 절반은 안 됩니다

Half of READMEs don't actually work

## 의존성이 빠져 있다

Missing system dependencies nobody documented

## 명령이 낡았다

Commands that broke three releases ago

## 아무도 다시 안 돌려봤다

Nobody re-ran it after the last merge

## LLM은 더 나쁘다

돌려본 적도 없이 "된다"고 지어냅니다.

An LLM will confidently say yes — it never ran anything.

# 묻지 않습니다. 돌려봅니다.

We don't ask. **We run it.**

```
verdict = (exit_code == 0) and ("REPRO_OK" in stdout)

# 판정은 모델의 의견이 아니라 종료 코드입니다.
# The verdict is an exit code, not a model's opinion.
# 신뢰도 = 실제로 통과한 샌드박스 비율 (모델 자기신고 아님)
# Confidence = fraction of sandboxes that actually passed.
```

# 스폰서 4개가 전부 필수 부품

All four sponsors are load-bearing

## MEASURE

### Daytona

샌드박스 환경을 추측하지 않고 직접 측정  
Probe, don't assume

## COLLECT

### Bright Data

SERP + 원격 크롬으로 README·정황 수집  
SERP + Scraping Browser

## DRAFT

### Qwen Cloud

서로 다른 전략 3벌 생성  
3 rival install strategies

## EXECUTE

### Daytona ×3

격리 샌드박스 병렬 실행  
Isolated, parallel, disposable

## SCALE

### Nosana

GPU 스텝을 탈중앙 GPU로  
Decentralized GPU offload

승자는 LLM이 고르지 않습니다. **실행 영수증으로 코드가 결정합니다.**

The winner is chosen by execution receipts, not by a model.

# 추측을 측정으로 바꾸자 전부 통과했습니다

We replaced one assumption with a measurement

**BEFORE** 가정: "root 권한, 네트워크 자유"      assumed root + open network  
Round 1 → 0/3 FAIL      (apt: Permission denied / httpbin: Connection reset)  
Round 2 → 3/3 PASS      자가수정 루프가 복구 self-repair loop recovered

**AFTER** 측정: uid=1001, sudo=passwordless, arbitrary\_http\_egress=blocked  
Round 1 → 3/3 PASS      재시도 없음 · 신뢰도 1.0      no retry needed

에이전트에게 진실을 주면 처음부터 맞춥니다.

Give the agent measured truth and it gets it right the first time.

실측 · MEASURED, NOT CLAIMED

# 모든 숫자는 실제 실행 결과입니다

Every number below came from a real run

| 스폰서 / SPONSOR | 사용 / WHAT WE USE                        | 실측 / OBSERVED                                    |
|---------------|-----------------------------------------|--------------------------------------------------|
| Bright Data   | SERP API · Scraping Browser (CDP)       | README 2,894자 · 원격 크롬 10.5s                      |
| Qwen Cloud    | <code>qwen3.8-max</code> workspace host | 드래프트 3벌 / 라운드                                    |
| Daytona       | Sandbox create · exec · delete          | 생성 <b>1.6s</b> · 병렬 3개                           |
| Nosana        | Markets · Jobs · API keys               | <code>nvidia-3060</code> <b>\$0.033/h</b> 최저가 선택 |

# 안 돌린 것을 통과로 세지 않습니다.

We never count what we didn't run.

```
routeStates: playwright Verified brightdata Verified
              agent-browser Not exercised dogfood Not exercised
completeFourRouteEvidence: false ← 스스로 미완성을 신고합니다
```

증거 등급은 넷뿐입니다 — Verified Failed Not exercised Blocked.

루트 간 불일치는 다수결로 지우지 않고 원장에 남깁니다.

Disagreement is recorded for investigation, never resolved by majority vote.

THANK YOU

돌려보지 않은 것은  
알지 못하는 것입니다.

If you didn't run it, you don't know it.

`github.com/pineapplesour/does-it-actually-run`