

AGENT FORGE AI HACKATHON SEOUL · 2026.08.22

Does It Actually Run?

README대로 진짜 되는지, 격리 샌드박스에서 **실제로 돌려보고** 판정합니다.

We don't ask a model whether it works. We run it, and read the exit code.

Bright Data

Qwen Cloud

Daytona

Nosana

README대로 하면, 절반은 안 됩니다

Half of READMEs don't actually work

의존성이 빠져 있다

Missing system dependencies nobody documented

명령이 낡았다

Commands that broke three releases ago

아무도 다시 안 돌려봤다

Nobody re-ran it after the last merge

LLM은 더 나쁘다

돌려본 적도 없이 "된다"고 지어냅니다.

An LLM will confidently say yes — it never ran anything.

묻지 않습니다. 돌려봅니다.

We don't ask. **We run it.**

```
verdict = (exit_code == 0) and ("REPRO_OK" in stdout)

# 판정은 모델의 의견이 아니라 종료 코드입니다.
# The verdict is an exit code, not a model's opinion.
# 신뢰도 = 실제로 통과한 샌드박스 비율 (모델 자기신고 아님)
# Confidence = fraction of sandboxes that actually passed.
```

스폰서 4개가 전부 필수 부품

All four sponsors are load-bearing

MEASURE

Daytona

샌드박스 환경을 추측하지 않고 직접 측정
Probe, don't assume

COLLECT

Bright Data

SERP + 원격 크롬으로 README·정황 수집
SERP + Scraping Browser

DRAFT

Qwen Cloud

서로 다른 전략 3벌 생성
3 rival install strategies

EXECUTE

Daytona ×3

격리 샌드박스 병렬 실행
Isolated, parallel, disposable

SCALE

Nosana

GPU 스텝을 탈중앙 GPU로
Decentralized GPU offload

승자는 LLM이 고르지 않습니다. **실행 영수증으로 코드가 결정합니다.**

The winner is chosen by execution receipts, not by a model.

4개 모두 코드 레벨에서 필수 부품

All four are load-bearing, at code level

Bright Data 2 products

Scraping Browser (CDP) - 원격 크롬에 connect_over_cdp 로 붙여
README 수집. 로컬은 GitHub 레이트리밋에 막힘

SERP API - 구글 검색으로 알려진 설치 실패 정황 수집

Also replaces Browserbase as Route 3, giving an external network
vantage the local routes cannot have.

`src/brightdata.py`

Qwen Cloud

`qwen3.8-max`, 워크스페이스 전용 호스트 사용 (동시성·격리)

README 를 읽고 서로 다른 전략 3벌 생성: literal / pragmatic / minimal
전멸하면 실제 에러 로그를 되먹여 재작성

Drafts rival install strategies, then repairs from real logs.

`src/llm.py`

Daytona the heart

① 환경 측정 - uid, sudo, egress 를 추측 대신 실측

② 병렬 실행 - 샌드박스 3개 동시, 생성 1.6s

③ 판정 - exit_code==0 && REPRO_OK 만이 통과

Without it the project does not exist. Execution is the only truth.

`src/daytona_runner.py`

Nosana

`/markets` `/jobs` `/api-keys` 실호출

가용 GPU 마켓을 조회해 최저가 노드 선택

실측: `nvidia-3060-community` \$0.033/h

Heavy verification steps offload to decentralized GPU.

`src/nosana.py`

추측을 측정으로 바꾸자 전부 통과했습니다

We replaced one assumption with a measurement

BEFORE 가정: "root 권한, 네트워크 자유" assumed root + open network
Round 1 → 0/3 FAIL (apt: Permission denied / httpbin: Connection reset)
Round 2 → 3/3 PASS 자가수정 루프가 복구 self-repair loop recovered

AFTER 측정: uid=1001, sudo=passwordless, arbitrary_http_egress=blocked
Round 1 → 3/3 PASS 재시도 없음 · 신뢰도 1.0 no retry needed

에이전트에게 진실을 주면 처음부터 맞춥니다.

Give the agent measured truth and it gets it right the first time.

실측 · MEASURED, NOT CLAIMED

모든 숫자는 실제 실행 결과입니다

Every number below came from a real run

스폰서 / SPONSOR	사용 / WHAT WE USE	실측 / OBSERVED
Bright Data	SERP API · Scraping Browser (CDP)	README 2,894자 · 원격 크롬 10.5s
Qwen Cloud	<code>qwen3.8-max</code> workspace host	드래프트 3벌 / 라운드
Daytona	Sandbox create · exec · delete	생성 1.6s · 병렬 3개
Nosana	Markets · Jobs · API keys	<code>nvidia-3060</code> \$0.033/h 최저가 선택

안 돌린 것을 통과로 세지 않습니다.

We never count what we didn't run.

```
routeStates: playwright Verified brightdata Verified
              agent-browser Not exercised dogfood Not exercised
completeFourRouteEvidence: false ← 스스로 미완성을 신고합니다
```

증거 등급은 넷뿐입니다 — Verified Failed Not exercised Blocked.

루트 간 불일치는 다수결로 지우지 않고 원장에 남깁니다.

Disagreement is recorded for investigation, never resolved by majority vote.

THANK YOU

돌려보지 않은 것은
알지 못하는 것입니다.

If you didn't run it, you don't know it.

`github.com/pineapplesour/does-it-actually-run`